# 中醫醫案術語抽取實驗結果分享

2018/10/02 林依蓁

#### 資料集

資料提供者:中醫在線(北京果壳宇宙教育科技有限公司)

簡述:傳統中醫醫案的人工摘要,以利使用者快速找到症狀相符之醫案

檔名:case\_summary\_180910.xls

檔案格式: Mocrosoft Excel File

內容格式: 共6個欄位(id, title, final\_content, source\_content, tags, summary)

資料筆數: 共2107筆

## 資料集 - 範例

id	3
title	桂枝汤治寒热不适
final_content	李某,女,67岁。每于夏日洗澡后即寒热不适,自感发热而又需披衣裹护。并于不知不觉中汗透衣服,急又换衣,如此三四次方渐趋平复。年年如此,以至夏日视洗澡为畏途。曾住院治疗不效。中医鉴于盛夏炎热,每以涤暑益气,敛汗固表为治,总不见效。三年前来我处就诊。症如前述,脉虚大而迟,苔薄黄。乃处桂枝汤加黄芪、炮附片,1剂效,2剂愈。后每年夏日发作,均来服药2剂即愈。
source_content	{诊次:李某, {性别:女}, {年龄:67岁}。{刻下:每于夏日洗澡后即寒热不适, 自感发热而又需披衣裹护。并于不知不觉中汗透衣服, 急又换衣, 如此三四次方渐趋平复。年年如此, 以至夏日视洗澡为畏途。}曾住院治疗不效。中医鉴于盛夏炎热, 每以涤暑益气, 敛汗固表为治, 总不见效。三年前来我处就诊。症如前述, {脉象:脉虚大而迟}, {舌象:苔薄黄}。乃处{处方名:桂枝汤加黄芪、炮附片}, 1剂效, 2剂愈。后每年夏日发作, 均来服药2剂即愈。}
tags	[{"name": "诊次", "child": [{"name": "性别", "content": "女"}, {"name": "年龄", "content": "67岁"}, {"name": "刻下", "content": "每于夏日洗澡后即寒热不适, 自感发热而又需披衣裹护。并于不知不觉中汗透衣服, 急又换衣, 如此三四次方渐趋平复。年年如此, 以至夏日视洗澡为畏途。"}, {"name": "脉象", "content": "脉虚大而迟"}, {"name": "舌象", "content": "苔薄黄"}, {"name": "处方名", "content": "桂枝汤加黄芪、炮附片"}], "content": "李某,女,67岁。每于夏日洗澡后即寒热不适,自感发热而又需披衣裹护。并于不知不觉中汗透衣服,急又换衣, 如此三四次方渐趋平复。年年如此, 以至夏日视洗澡为畏途。曾住院治疗不效。中医鉴于盛夏炎热, 每以涤暑益气, 敛汗固表为治, 总不见效。三年前来我处就诊。症如前述, 脉虚大而迟, 苔薄黄。乃处桂枝汤加黄芪、炮附片, 1剂效, 2剂愈。后每年夏日发作, 均来服药2剂即愈。"}]
summary	{"main": "寒热不适, 发热又需披衣, 汗透衣服', "pulse": "脉虚大而迟", "recipe": {"raw": "", "memo": "", "title": "桂枝汤"}, "second": "", "tongue": "苔薄黄", "chinese": "发热", "therapy": "", "western": "", "dialectical": ""}

#### 資料集 - 範例

"therapy": "",

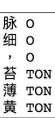
"western": "",

"dialectical": ""}

李某、女、67岁。每于夏日洗澡后即寒热不适、自感发热而又需披衣裹护。并于不知不觉 原文 中汗透衣服、急又换衣、如此三四次方渐趋平复。年年如此、以至夏日视洗澡为畏途。曾住 (final content) 院治疗不效。中医鉴于盛夏炎热, 每以涤暑益气, 敛汗固表为治, 总不见效。三年前来我处 就诊。症如前述,脉虚大而迟,苔薄黄。乃处桂枝汤加黄芪、炮附片,1剂效,2剂愈。后每 年夏日发作,均来服药2剂即愈。 {"main": "寒热不适, 发热又需披衣, 汗透衣服", 摘要 public \$summaryKey = array( "pulse": "脉虚大而迟", 'main' (summary) 'second' "recipe": {"raw": "", "memo": "", "title": "桂枝汤"}, "second": "", 'pulse' "tongue": "苔薄黄", 'dialectical' 'therapy' "chinese": "发热".

#### 預處理

- 移除標點
- 拆分為句
  - 以全形句點(。)將醫案拆分為句(sentence), 以句子作為資料點。
  - 拆分後共得**48901筆**, 平均句長32.5個字。
- 詞位標注
  - 標注集: OS
  - 實體類別: SYM(合併主證與兼證), PUL(脈象), TON(舌象)
- 逐字標註
  - 共有3235個症狀詞(TON), 其中43個詞沒有完全對應, 皆標為 O。
  - 範例
    - content:脉细,苔薄黄
    - tongue: "苔薄黄"
    - 標注結果:脉〇细〇, O苔TON薄TON黄TON



#### 預處理

- 移除標點
- 拆分為句
  - 以全形句點(。)將醫案拆分為句(sentence), 以句子作為資料點。
  - 拆分後共得**48901筆**, 平均句長32.5個字。
- 詞位標注
  - 標注集: OSBIE
  - 實體類別: SYM(合併主證與兼證), PUL(脈象), TON(舌象)
- 逐字標註
  - 共有13452個症狀詞(SYM), 其中671個詞沒有完全對應, 皆標為O。
  - 範例:
    - content:每于夏日洗澡后即寒热不适,自感发热而又需披衣裹护
    - main": "寒热不适,发热又需披衣,汗透衣服"
    - 標注結果:每〇丁〇夏〇日〇洗〇澡〇后〇即〇寒B-SYM热I-SYM不I-SYM适 E-SYM. 〇自〇感〇发〇热〇而〇又〇需〇披〇衣〇裹〇护〇

每 o 于。 夏0 H 洗o 澡 o 后o 寒 B-SYM 热 I-SYM 不 I-SYM 括 E-SYM , 0 自の 感o 发o 热o 而の 又の 需の 披o 衣o 裹 0 护 o

#### 模型訓練

- 模型:條件隨機場(CRF)
- 工具包: python-crfsuite
- 詞性標注系統:NLTK,ICTCLAS
- 資料集:
  - 將症狀,脈象,舌象分別標註為三個資料集
    - 症狀詞資料集: SYM
    - 脈象詞資料集: PUL
    - 舌象詞資料集: TON
  - 將資料集切分為訓練集和測試集
    - 80%作為訓練集(39120筆)
    - 20%作為測試集(9781筆)
- 特徵:字本身,前一個字,後一個字,詞性

'word',
'word.isdigit',
'postag',

- '-1:word',
- '-1:word.isdigit',
- '-1:postag',
- '+1:word',
- '+1:word.isdigit',
- '+1:postag'

## 條件隨機場(Conditional Radom Fiels, CRF)

- 機率模型
- 常用於標注或分析序列資料
- 通過可觀測狀態(observeable/labels)判別隱含變量(hidden variables), 其概率 亦通過標註集統計得來, 是一個判別模型。
- 條件隨機場是邏輯迴歸的串行化版本。邏輯迴歸是用於分類的對數線性模型,條件隨機場是用於串行化標註的對數線性模型。

- 資料集: 舌象詞資料集

- 資料筆數: 2107筆 - 平均句長: 606字

- 演算法: CRF - 類別標註: OS

- 詞性標註: ICTCLAS

- 詞位標注: 無 - 引用辭典: 無 - 去標點: 無

- 拆句: 無 - 斷詞: 無

F1 score for	training s	et:		
	precision	recall	f1-score	support
0 S	1.00 0.61	1.00 0.31	1.00 0.41	1305864 8932
5	0.61	0.31	0.41	0932
avg / total	0.99	0.99	0.99	1314796
F1 score for	test set:			
	precision	recall	f1-score	support
О	1.00	1.00	1.00	320988
s	0.53	0.26	0.35	2136
avg / total	0.99	0.99	0.99	323124

- f1-score 很差
- training set 與 test set 的分數差異不高



Underfitting

實驗 #1:比較是否拆句 (recall 效果顯著)

實驗變因	不拆句 (2107筆 / 平	拆句 (4890	拆句 (48901筆 / 平均32.5字)							
控制變因	- 斷詞: 無 - 詞位標注: 無			- 斷詞: 無 - 詞位標注:	- 斷詞: 無 - 詞位標注: 無					
數值	F1 score for training	ng set:		F1 score for	training se	t:				
	precis	ion recall	f1-score	support		precision	recall	f1-score	support	
		.00 1.00 .61 0.31	1.00 0.41	1305864 8932	O S	1.00 0.67	1.00	1.00 0.75	1259654 12942	
	avg / total 0	.99 0.99	0.99	1314796	avg / total	1.00	0.99	0.99	1272596	
	F1 score for test s	et:			F1 score for	test set:				
	precis	ion recall	f1-score	support		precision	recall	f1-score	support	
		.00 1.00 .53 0.26	1.00 0.35	320988 2136	O S	1.00 0.65	1.00 0.84	1.00 0.74	315324 3206	
	avg / total 0	.99 0.99	0.99	323124	avg / total	0.99	0.99	0.99	318530	

實驗 #2: 比較不同句長 (短句的recall效果顯著, overfitting?)

實驗變因	不拆句 (平均句長	拆句 (平均句長32.5字)								
控制變因	- 資料筆數:2107 - 斷詞:無 - 詞位標注: 無	- 資料筆數:2107筆 - 斷詞:無 - 詞位標注: 無								
數值	F1 score for trai	ning se	t:		F1 score for	training se	t:			
	prec	ision	recall	f1-score	support		precision	recall	f1-score	support
	o s	1.00	1.00 0.31	1.00 0.41	1305864 8932	0 S	1.00	1.00	1.00 0.84	55059 482
	avg / total	0.99	0.99	0.99	1314796	avg / total	1.00	1.00	1.00	55541
	F1 score for test	set:				F1 score for	test set:			
	prec	ision	recall	f1-score	support		precision	recall	f1-score	support
	0	1.00	1.00	1.00	320988	0	1.00	1.00	1.00	13036
	s	0.53	0.26	0.35	2136	s	0.72	0.64	0.68	126
	avg / total	0.99	0.99	0.99	323124	avg / total	0.99	0.99	0.99	13162

實驗 #3:比較是否斷詞 (precision 效果顯著)

實驗變因	<b>斷詞:無</b>	斷詞:有								
控制變因	- 拆句 (4890 - 詞位標注:新	- 拆句 (48901筆 / 平均32.5字) - 詞位標注:無								
數值	F1 score for	training se	t:			F1 score for	training se	t:		
		precision	recall	f1-score	support		precision	recall	f1-score	support
	o s	1.00 0.67	1.00 0.86	1.00 0.75	1259654 12942	0 s	1.00	1.00 0.84	1.00 0.84	909469 16602
	avg / total	1.00	0.99	0.99	1272596	avg / total	0.99	0.99	0.99	926071
	F1 score for					F1 score for	test set:			
		precision		f1-score	support		precision	recall	f1-score	support
	o s	1.00 0.65	1.00 0.84	1.00 0.74	315324 3206	0 S	1.00 0.80	1.00 0.83	1.00 0.81	224580 3917
	avg / total	0.99	0.99	0.99	318530	avg / total	0.99	0.99	0.99	228497

實驗 #4:增加詞位標註 (影響不大)

實驗變因	詞位標注: 無	詞位標注: 有								
控制變因	- 拆句 (48901筆 - 斷詞:無	- 拆句 (48901筆 / 平均32.5字) - 斷詞 :無								
數值	F1 score for tra	ining set	: <b>:</b>		F1 score for	training se	t:			
	pre	cision	recall	f1-score	support		precision	recall	f1-score	support
						0	1.00	1.00	1.00	1262835
	0	1.00	1.00	1.00	1259654	B-SYM	0.68	0.85	0.75	3805
	S	0.67	0.86	0.75	12942	I-SYM	0.67	0.89	0.77	5239
						E-SYM	0.67	0.85	0.75	3795
	avg / total	1.00	0.99	0.99	1272596	avg / total	1.00	0.99	0.99	1275674
	F1 score for tes	t set:				F1 score for	test set:			
	pre	cision	recall	f1-score	support		precision	recall	f1-score	support
		1 00	1 00	1 00	215204	0	1.00	1.00	1.00	312143
	0	1.00	1.00	1.00	315324	B-SYM	0.65	0.80	0.72	977
	S	0.65	0.84	0.74	3206	I-SYM	0.64	0.81	0.72	1357
						E-SYM	0.64	0.80	0.71	975
	avg / total	0.99	0.99	0.99	318530					
						avg / total	0.99	0.99	0.99	315452

#### 預測結果案例 - 1

[摘要]:舌淡苔白腻

[原文]:二诊(2009年12月26日):药后纳食增加,再未呕吐,面色较前红润, <mark>舌淡苔白略腻</mark>,脉细。

[摘要]:舌黯红、苔薄黄

[原文]:察其<mark>舌黯红,苔薄黄</mark>,左脉弦细,右脉沉滑

[摘要]:舌红, 苔少

[原文]:<mark>舌红</mark>, <mark>苔少</mark>, 脉沉细



#### 預測結果案例 - 2

[摘要]:舌质黯淡、舌体偏大、舌苔白滑腻

[原文]: 舌质淡红, 舌体偏大, 舌苔薄白, 脉象沉细缓和

[摘要]:舌质紫黯,舌苔薄白

[原文]:四诊(2009年4月1日):胃脘胀满,大腿沉重,睡眠不佳,双膝疼痛微僵,气喘、胸闷,咳嗽减轻,痰少,双下肢浮肿,舌质

<mark>黯淡, 苔</mark>黄厚,脉象脉弦数

[摘要]:舌质黯红、苔厚腻

[原文]:三诊(2002年5月29日):患者诉胸闷显著减轻,心悸偶作,食眠皆正常,大便通畅,小便调,仍觉气短乏力,<mark>舌质稍黯、苔</mark>

白,脉沉

True Positiive \_\_\_ False Positive

#### 預測結果案例 - 3

[摘要]: 苔微黄腻、舌质黯红

[原文]:按:以失眠为主症并有脑血管病者,临床上除失眠、早醒或间断多醒外,常见头晕、头胀痛或脑响、耳鸣、心烦'易怒,记忆

力减退或头颈板滞不适,时手抖手麻、口干苦、大便偏干,面赤或<mark>黯红</mark>、呆滞缺润彩,<mark>苔黄</mark>、<mark>舌红</mark>或偏<mark>绛红</mark>,脉弦紧

[摘要]:舌黯红而干、苔薄白

[原文]:《类证治裁》中说:"胸痹胸中阳微不运, 久则阴乘阳位而为痹结也

[摘要]: 苔薄白, 舌质黯紫有瘀斑

[原文]:故仍<mark>有</mark>胸闷,神倦,夜寐欠安,喜太息,口唇青紫,<mark>舌黯紫</mark>,<mark>苔</mark>薄白,脉细涩

[摘要]:舌质淡红, 无苔

[原文]:四诊(2008年11月13日):药后患者咳嗽明显好转,咳痰色白质稀量少,无咽痒,口舌略干燥,近1周眼睛干涩明显好转,

<mark>舌质淡红,</mark>无苔,脉沉细数

True Positiive \_\_\_ False Positive \_\_\_ False Negative

#### - 資料集: 脈象詞資料集

- 資料筆數: 48901筆 - 平均句長: 32.5字

- 演算法: CRF

- 類別標註: O,PUL

- 詞性標註: ICTCLAS

- 詞位標注: 無 - 引用辭典: 無

- 去標點: 無

- 拆句: 有 - 斷詞: 有

F1 score fo	r training s	et:		
	precision	recall	f1-score	support
o	1.00	1.00	1.00	913259
PUL	0.86	0.89	0.88	12591
avg / total	1.00	1.00	1.00	925850
F1 score fo	r test set:			
	precision	recall	f1-score	support
O		1.00 0.87	1.00 0.86	225849 3132
avg / total	1.00	1.00	1.00	228981

- 資料集: 症狀詞資料集

- 資料筆數: 48901筆 - 平均句長: 32.5字

- 演算法: CRF - 類別標註: OS

- 詞性標註: ICTCLAS

- 詞位標注: 無 - 引用辭典: 無 - 去標點: 無

- 拆句: 無 - 斷詞: 無

F1 score for	e for training set:									
	precision	recall	f1-score	support						
О	0.97	0.98	0.97	851330						
s	0.72	0.57	0.64	69776						
avg / total	0.95	0.95	0.95	921106						
F1 score for	test set:									
	precision	recall	f1-score	support						
О	0.96	0.98	0.97	216777						
s	0.65	0.53	0.58	16952						
avg / total	0.94	0.95	0.94	233729						

● f1-score 不佳

training set 與 test set 的分數差異7%



Underfitting

更多實驗:(效果不顯著)

202 20300 ()							
資料集	症狀詞						
資料筆數(拆句)	48901筆	48901筆	33752筆	2107筆	2107筆	2107筆	1436筆
詞性標註系統	NLTK	ICTCLAS	NLTK	NLTK	NLTK	NLTK	NLTK
去標點	無	無	無	無	有	無	無
引用辭典	無	無	無	無	無	有	無
詞位標注	BIEO						
B-SYM (precision / recall)	0.59 / 0.46	0.60 / 0.46	0.61 / 0.46	0.45 / 0.18	0.45 / 0.12	0.44 / 0.18	0.48 / 0.20
I-SYM (precision / recall)	0.52 / 0.33	0.50 / 0.31	0.52 / 0.36	0.39 / 0.19	0.40 / 0.10	0.40 / 0.20	0.40 / 0.22
E-SYM (precision / recall)	0.60 / 0.47	0.61 / 0.46	0.63 / 0.48	0.45 / 0.18	0.47 / 0.13	0.46 / 0.19	0.49 / 0.21

## 問題探討(改進方向)

#### ● 資料預處理

- 逐字標註時, 若包含了沒有完全對應的症狀詞, 應該整筆移除。目前做法是標注為 O。
- 以句點拆句之後的句長差異頗大,若超過一定長度則再切短。

#### ● 引入辭典

#### ● 分詞效能

○ 從分詞工具著手,在分詞階段就取得較好的結果。目前作法是使用中科院 ICTCLAS系統

#### ● 過濾停用字

○ 分詞後過濾停用字 (stop words)

簡報完畢 敬請指教